3. Comprensión del negocio

Muchos proyectos de ciencia de datos se tuercen antes de que alguien abra un cuaderno de Python. La primera fase de CRISP-DM pide entender qué quiere lograr la organización y traducirlo a una pregunta que los datos puedan responder. La guía la divide en cuatro tareas: definir los objetivos del negocio, evaluar la situación (recursos, restricciones y riesgos), fijar las metas analíticas y trazar un plan de proyecto [1].

Provost y Fawcett señalan que en esta etapa pesa más que en ninguna otra la creatividad del analista, porque una misma base de datos admite preguntas muy distintas y cada una conduce a un modelo diferente [2]. Un equipo que se salta esta traducción puede entregar un modelo correcto que responde algo que a nadie le interesa. Martínez-Plumed et al. encontraron que en muchos proyectos actuales el objetivo no está claro al comienzo y aparece mientras se exploran los datos [3]. En esos casos el equipo vuelve a esta fase varias veces, y cada regreso cuesta menos si la primera versión quedó por escrito.

Tomemos un caso que servirá de hilo para esta sección y las dos siguientes. Una cadena de 40 supermercados pierde ventas por quiebres de inventario y, a la vez, acumula mercancía que no rota. La gerencia pide "usar los datos para mejorar el inventario", una frase que todavía no es un problema analítico. La Tabla 2 la descompone en preguntas que los datos sí pueden contestar.

Tabla 2. Traducción de objetivos de negocio a objetivos analíticos (caso hipotético de una cadena de supermercados).

Objetivo de negocio	Pregunta analítica	Tipo de tarea	Criterio de éxito analítico
Reducir los quiebres de inventario	¿Cuántas unidades venderá cada tienda la próxima semana?	Regresión (pronóstico)	MAPE menor al 10 % en las semanas de validación
Reducir el capital inmovilizado en bodega	¿Qué rango de demanda es razonable esperar cada semana?	Regresión con intervalos de predicción	90 % de las semanas reales dentro del intervalo
Planear promociones con retorno positivo	¿Cuánto cambian las ventas con el precio y la promoción?	Regresión explicativa	Coeficientes con el signo esperado y estables entre periodos
Asignar el personal de reposición	¿Qué tiendas tienen patrones de demanda parecidos?	Agrupamiento	Grupos que el área comercial reconoce y puede usar

Fuente: elaboración propia a partir de la estructura de la fase de comprensión del negocio de CRISP-DM [1].

La última columna evita muchas discusiones posteriores. CRISP-DM distingue el criterio de éxito del negocio (menos quiebres, menos inventario parado) del criterio de éxito analítico, que aquí es un error de pronóstico aceptable [1]. Si ese umbral se acuerda al inicio, la evaluación tiene contra qué medir; si no, cualquier resultado puede presentarse como bueno. También conviene

dejar escrito el alcance: el proyecto pronostica, y la decisión de cuánto pedir sigue en manos del área de compras.

4. Comprensión de los datos

Con la pregunta definida, hay que saber si los datos alcanzan para responderla. CRISP-DM organiza esta fase en cuatro tareas: recolectar los datos iniciales, describirlos, explorarlos y verificar su calidad [1]. Sostenemos que esta fase fija el techo del proyecto, porque ningún algoritmo recupera información que los datos no contienen y un sesgo que nadie detecta aquí termina dentro del modelo.

Wang y Strong encuestaron a usuarios de información y concluyeron que la calidad de los datos tiene varias dimensiones: además de la exactitud, cuentan la pertinencia para la tarea, la oportunidad, la completitud y la facilidad de interpretación [4]. Un registro exacto sigue siendo inútil si llega tarde o no cubre el periodo que se quiere modelar.

Los estadísticos de resumen tampoco bastan. Anscombe construyó cuatro conjuntos de datos con la misma media, varianza, correlación y recta de regresión que, al graficarlos, resultan muy distintos: uno es lineal, otro es curvo y en los otros dos un solo punto extremo determina la recta [5]. Por eso Tukey defendía el análisis exploratorio como una etapa propia, en la que primero se grafica y después se supone [6]. La lección aplica de lleno a una regresión, cuya recta se calcula igual sobre datos buenos que sobre datos defectuosos.

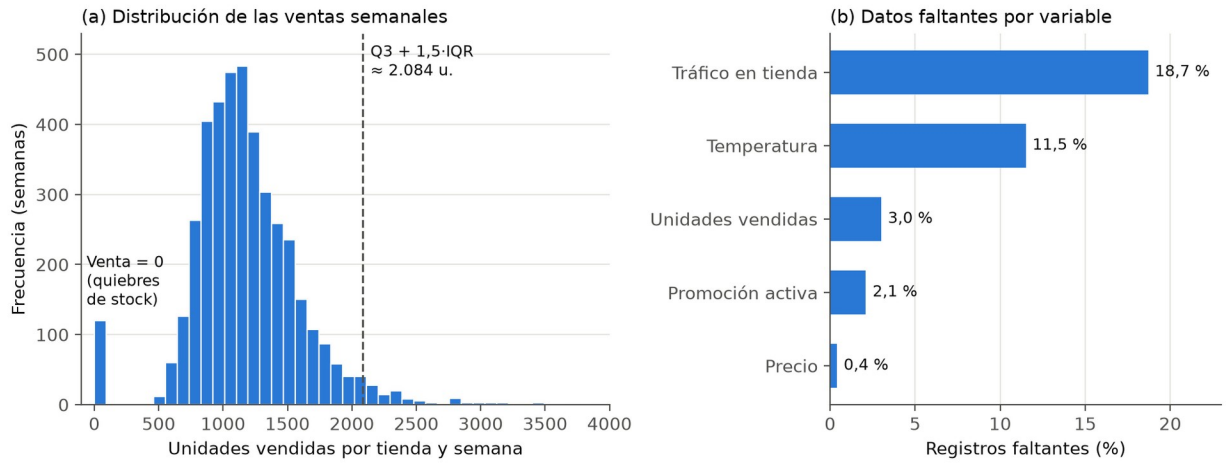


Figura 2. Exploración inicial de los datos del caso: (a) distribución de las ventas semanales por tienda, con el umbral de atípicos de la ecuación (1); (b) porcentaje de registros faltantes por variable. Datos simulados con fines ilustrativos.

La Figura 2 resume una exploración inicial del caso. En el panel (a) las ventas semanales tienen una distribución asimétrica: la mayoría de las semanas está entre 800 y 1.600 unidades y la cola derecha corresponde a festivos. Aparece además una barra aislada en cero, formada por

semanas en las que el producto no estaba en el estante. Las ventas registradas miden lo que se vendió, que puede ser menos de lo que se habría vendido. Si esos ceros entran al modelo como demanda real, el pronóstico sale sesgado hacia abajo justo en las tiendas con más quiebres, y el proyecto refuerza el problema que quería resolver.

El panel (b) muestra que el tráfico en tienda falta en casi el 19 % de los registros y la temperatura en el 11,5 %. Antes de rellenar esos vacíos hay que averiguar por qué existen. Si el contador de personas solo se instaló en las tiendas nuevas, los faltantes no son aleatorios y un promedio mezclaría dos poblaciones distintas. Mehrabi et al. llaman a esto sesgo de representación: el modelo aprende sobre todo de los grupos bien cubiertos y funciona peor para los demás [7].

El entregable de la fase es un informe de calidad de datos [1]. A veces ese informe obliga a regresar a la fase anterior: si los datos no permiten estimar la demanda con la granularidad pedida, el objetivo de negocio se ajusta.

5. Preparación de los datos

La preparación decide con qué va a aprender el modelo. CRISP-DM la divide en cinco tareas: seleccionar, limpiar, construir, integrar y dar formato a los datos [1]. Suele decirse que ocupa el 80 % del tiempo de un científico de datos, aunque esa cifra proviene de encuestas de la industria con métodos poco documentados. En la encuesta de Anaconda de 2020, los participantes reportaron que cargar y limpiar datos ocupa en promedio el 45 % de su jornada, frente a un 11 % o 12 % para cada una de las tareas de selección, entrenamiento y despliegue de modelos [8]. Aun con la cifra más baja, es la actividad que más tiempo consume.

Limpiar empieza por los faltantes. Little y Rubin distinguen datos que faltan completamente al azar (MCAR), al azar condicionado a otras variables observadas (MAR) y por razones ligadas al propio valor ausente (MNAR) [9]. El mecanismo determina el tratamiento. La temperatura faltante puede tomarse de una estación meteorológica cercana. El tráfico que falta porque la tienda no tiene contador depende de su antigüedad, una variable observada, así que es un caso MAR y conviene añadir una variable indicadora en vez de inventar valores. Los ceros por quiebre se marcan y se excluyen del entrenamiento.

Para los valores atípicos, una regla sencilla y robusta es la de Tukey [6], que marca como atípico todo valor que cumpla

$$x < Q_1 - 1{,}5 \cdot IQR \;\vee\; x > Q_3 + 1{,}5 \cdot IQR, \quad IQR = Q_3 - Q_1 \tag{1}$$

donde Q_1 y Q_3 son el primer y el tercer cuartil. En la Figura 2(a) el límite superior queda cerca de 2.084 unidades. Marcar un valor no equivale a borrarlo: las semanas por encima del límite son festivos, y si se eliminan el modelo no sabrá qué ocurre en diciembre, cuando más importa acertar. Lo correcto es conservarlas y añadir una variable de temporada.

También hay que llevar las variables a escalas comparables, pues el precio se mide en miles de pesos, la temperatura en grados y el tráfico en cientos de personas. Han, Kamber y Pei describen dos transformaciones comunes [10]. La normalización min-max lleva cada variable al intervalo [0, 1]:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{2}$$

y la estandarización (puntuación z) expresa cada valor en desviaciones estándar respecto a la media:

$$z = \frac{x - \mu}{\sigma} \tag{3}$$

donde μ es la media y σ la desviación estándar. Si una tienda vende en promedio 1.200 unidades semanales con $\sigma = 300$, una semana de 1.950 unidades tiene $z = (1.950 - 1.200)/300 = 2{,}5$. La normalización min-max es sensible a los extremos, porque un solo atípico comprime los demás valores cerca de cero, así que conviene aplicarla después de tratar los atípicos.

En mínimos cuadrados ordinarios, escalar no cambia las predicciones. Sí importa con regularización (ridge o lasso), porque la penalización actúa sobre el tamaño de los coeficientes y castigaría de forma desigual a variables con unidades distintas; por eso James et al. recomiendan estandarizar los predictores antes de ajustar una regresión ridge [11]. Con variables estandarizadas, además, los coeficientes se pueden comparar entre sí, lo que ayuda a responder la tercera pregunta de la Tabla 2.

De un detalle técnico depende que la evaluación posterior sea honesta: la media, la desviación, el mínimo y el máximo de las ecuaciones (2) y (3) se calculan solo con los datos de entrenamiento y luego se aplican a los de validación. Si se calculan con todo el conjunto, el modelo recibe información del periodo con el que será evaluado. Kaufman et al. llaman a esto fuga de información (*leakage*) y muestran que produce resultados optimistas que no se repiten en la práctica [12]. En ventas semanales, además, la separación debe hacerse por fecha y no al azar.

Por último, integrar ventas, precios, promociones y clima exige una unidad de observación común. Wickham propone el formato ordenado (*tidy data*): cada variable en una columna, cada observación en una fila y cada tipo de unidad observacional en su propia tabla [13]. Aquí la

observación es tienda-semana. La fase entrega un conjunto listo para modelar y un registro de cada transformación, para repetirlas cuando lleguen datos nuevos. Con esa base, el modelado puede concentrarse en elegir el algoritmo según el problema, tema de la siguiente sección.

Referencias

[1] P. Chapman et al., *CRISP-DM 1.0: Step-by-Step Data Mining Guide*. Chicago, IL, USA: SPSS Inc., 2000.

[2] F. Provost y T. Fawcett, *Data Science for Business: What You Need to Know About Data Mining and Data-Analytic Thinking*. Sebastopol, CA, USA: O'Reilly Media, 2013.

[3] F. Martínez-Plumed et al., "CRISP-DM twenty years later: From data mining processes to data science trajectories," *IEEE Trans. Knowl. Data Eng.*, vol. 33, no. 8, pp. 3048–3061, ago. 2021, doi: 10.1109/TKDE.2019.2962680.

[4] R. Y. Wang y D. M. Strong, "Beyond accuracy: What data quality means to data consumers," *J. Manage. Inf. Syst.*, vol. 12, no. 4, pp. 5–33, 1996, doi: 10.1080/07421222.1996.11518099.

[5] F. J. Anscombe, "Graphs in statistical analysis," *Amer. Statist.*, vol. 27, no. 1, pp. 17–21, 1973, doi: 10.1080/00031305.1973.10478966.

[6] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[7] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman y A. Galstyan, "A survey on bias and fairness in machine learning," *ACM Comput. Surv.*, vol. 54, no. 6, art. 115, pp. 1–35, 2021, doi: 10.1145/3457607.

[8] Anaconda Inc., "2020 State of Data Science: Moving from hype toward maturity," Austin, TX, USA, 2020. [En línea]. Disponible: https://www.anaconda.com/resources/whitepaper/state-of-data-science-2020. Consultado: 27 sep. 2026.

[9] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 3.ª ed. Hoboken, NJ, USA: Wiley, 2019.

[10] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 3.ª ed. Waltham, MA, USA: Morgan Kaufmann, 2012.

[11] G. James, D. Witten, T. Hastie y R. Tibshirani, *An Introduction to Statistical Learning: With Applications in R*, 2.ª ed. Nueva York, NY, USA: Springer, 2021.

[12] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, art. 15, pp. 1–21, 2012, doi: 10.1145/2382577.2382579.

[13] H. Wickham, "Tidy data," *J. Stat. Softw.*, vol. 59, no. 10, pp. 1–23, 2014, doi: 10.18637/jss.v059.i10.