3. Comprensión del negocio

Muchos proyectos de ciencia de datos se tuercen antes de que alguien abra un cuaderno de Python. La primera fase de CRISP-DM pide entender qué quiere lograr la organización y traducirlo a una pregunta que los datos puedan responder [1]. La guía original divide esta fase en cuatro tareas: definir los objetivos del negocio, evaluar la situación (recursos, restricciones, riesgos y supuestos), fijar las metas de minería de datos y trazar un plan de proyecto [1]. El orden tiene sentido, porque las metas analíticas se derivan de las del negocio y cada una necesita su propio criterio de éxito.

Provost y Fawcett señalan que la comprensión del negocio es la etapa donde más pesa la creatividad del analista, ya que una misma base de datos admite preguntas muy distintas y cada pregunta conduce a un modelo diferente [2]. Un equipo que se salta esta traducción puede entregar un modelo técnicamente correcto que responde algo que a nadie en la empresa le interesa. Martínez-Plumed et al. revisaron el uso de CRISP-DM dos décadas después de su publicación y encontraron que en muchos proyectos actuales el objetivo no está claro desde el comienzo; a veces aparece mientras se exploran los datos [3]. De ese hallazgo sacamos una consecuencia práctica: cuando el objetivo es difuso, el equipo vuelve a esta fase varias veces, y cada regreso cuesta menos si la primera versión quedó por escrito.

Tomemos un caso que servirá de hilo para esta sección y las dos siguientes. Una cadena de supermercados con 40 tiendas pierde ventas por quiebres de inventario y, al mismo tiempo, acumula mercancía que no rota. La gerencia pide "usar los datos para mejorar el inventario". Esa frase todavía no es un problema analítico. La Tabla 2 muestra cómo puede descomponerse en preguntas que los datos sí pueden contestar.

Tabla 2. Traducción de objetivos de negocio a objetivos analíticos (caso hipotético de una cadena de supermercados).

Objetivo de negocio	Pregunta analítica	Tipo de tarea	Criterio de éxito analítico
Reducir los quiebres de inventario	¿Cuántas unidades venderá cada tienda la próxima semana?	Regresión (pronóstico)	MAPE menor al 10 % en las semanas de validación
Reducir el capital inmovilizado en bodega	¿Qué rango de demanda es razonable esperar cada semana?	Regresión con intervalos de predicción	90 % de las semanas reales dentro del intervalo
Planear promociones con retorno positivo	¿Cuánto cambian las ventas con el precio y la promoción?	Regresión explicativa	Coeficientes con el signo esperado y estables entre periodos
Asignar el personal de reposición	¿Qué tiendas tienen patrones de demanda parecidos?	Agrupamiento	Grupos que el área comercial reconoce y puede usar

Fuente: elaboración propia a partir de la estructura de la fase de comprensión del negocio de CRISP-DM [1].

La última columna es la que más discusiones evita más adelante. CRISP-DM distingue entre el criterio de éxito del negocio (menos quiebres, menos inventario parado) y el criterio de éxito de minería de datos, que en el ejemplo es un error de pronóstico aceptable [1]. Si ese umbral se acuerda al inicio, la fase de evaluación tiene contra qué medir; si no se acuerda, cualquier resultado puede presentarse como bueno. En esta fase también conviene dejar escrito lo que el proyecto no va a hacer. Aquí el alcance se limita a pronosticar, y la decisión de cuánto pedir la sigue tomando el área de compras.

4. Comprensión de los datos

Con la pregunta definida, el equipo necesita saber si los datos disponibles alcanzan para responderla. CRISP-DM organiza esta fase en cuatro tareas: recolectar los datos iniciales, describirlos, explorarlos y verificar su calidad [1]. Sostenemos que esta fase fija el techo del proyecto. Ningún algoritmo recupera información que los datos no contienen, y un sesgo que nadie detecta aquí termina incorporado en el modelo.

La calidad de los datos no se reduce a que estén bien digitados. Wang y Strong encuestaron a usuarios de información y concluyeron que la calidad tiene varias dimensiones: además de la exactitud, cuentan la pertinencia para la tarea, la oportunidad, la completitud y la facilidad para interpretar los datos [4]. Un registro puede ser exacto y aun así inútil si llega tarde o si no cubre el periodo que se quiere modelar.

Los estadísticos de resumen tampoco bastan. Anscombe construyó cuatro conjuntos de datos con la misma media, la misma varianza, la misma correlación y la misma recta de regresión; al graficarlos, el primero es aproximadamente lineal, el segundo es una curva, en el tercero un solo punto atípico desvía la recta y en el cuarto la pendiente depende de un único valor extremo [5]. Tukey defendía por razones como esta el análisis exploratorio como una etapa propia, en la que primero se grafica y después se supone [6]. Para un proyecto de regresión la lección es directa, porque la recta de mínimos cuadrados se calcula igual sobre datos buenos que sobre datos defectuosos.

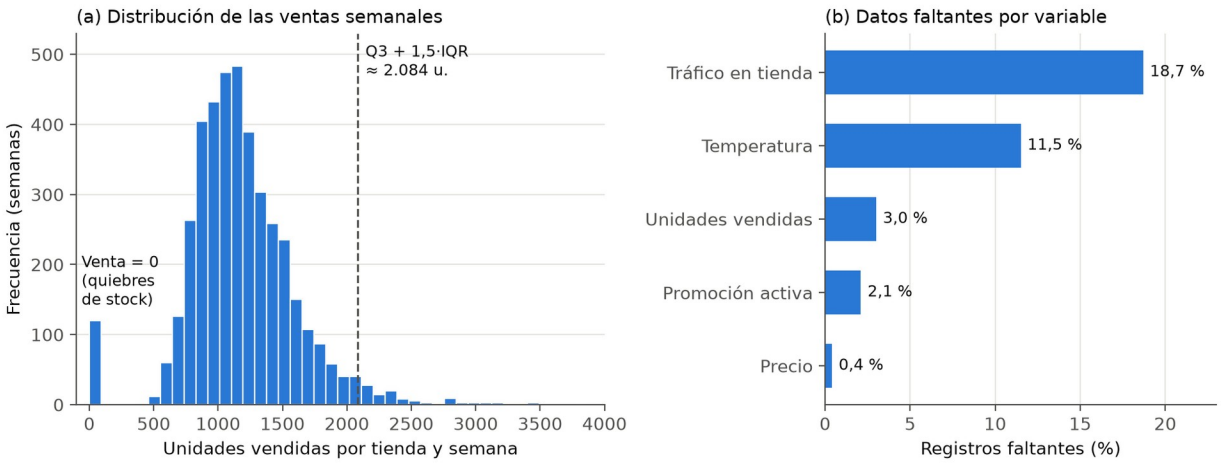


Figura 2. Exploración inicial de los datos del caso: (a) distribución de las ventas semanales por tienda, con el umbral de atípicos de la ecuación (1); (b) porcentaje de registros faltantes por variable. Datos simulados con fines ilustrativos.

La Figura 2 resume una exploración inicial del caso. En el panel (a) la distribución de las ventas semanales es asimétrica hacia la derecha: la mayoría de las semanas está entre 800 y 1.600 unidades, y la cola larga corresponde a semanas festivas. Aparece además una barra aislada en cero. Esas semanas no indican que faltaran clientes; son semanas en las que el producto no estaba en el estante. Las ventas registradas miden lo que se vendió, y eso no siempre coincide con lo que se habría vendido. Si esos ceros entran al modelo como demanda real, el pronóstico sale sesgado hacia abajo justamente en las tiendas que más sufren quiebres, y el proyecto acaba reforzando el problema que quería resolver.

El panel (b) muestra que el tráfico en tienda falta en casi el 19 % de los registros y la temperatura en el 11,5 %. Antes de decidir qué hacer con esos vacíos hay que averiguar por qué existen. Si el contador de personas solo se instaló en las tiendas más nuevas, los faltantes no son aleatorios, y rellenarlos con un promedio mezclaría dos poblaciones distintas. Mehrabi et al. describen este tipo de problema como sesgo de representación: cuando una parte de la población queda mal cubierta en los datos, el modelo aprende sobre todo del resto y funciona peor para el grupo subrepresentado [7].

El entregable de esta fase es un informe de calidad de datos que indique qué variables sirven, cuáles necesitan tratamiento y cuáles se descartan [1]. Ese informe a veces obliga a regresar a la fase anterior. Si los datos no permiten estimar la demanda con la granularidad que se pidió, el objetivo de negocio tiene que ajustarse.

5. Preparación de los datos

En la preparación de los datos se decide, en buena medida, con qué va a aprender el modelo. CRISP-DM la divide en cinco tareas: seleccionar, limpiar, construir, integrar y dar formato a los datos [1]. Es también la fase que más horas consume. Circula con frecuencia la cifra de que el 80 % del tiempo de un científico de datos se dedica a preparar datos, aunque suele provenir de encuestas de la industria con métodos poco documentados. Una fuente más verificable es la encuesta de Anaconda de 2020, cuyos participantes reportaron que cargar y limpiar datos ocupa en promedio el 45 % de su jornada, mientras que la selección, el entrenamiento y el despliegue de modelos ocupan entre el 11 % y el 12 % cada uno [8]. Con cualquiera de las dos cifras, la preparación consume más tiempo que cualquier otra actividad del proyecto.

Limpiar empieza por los faltantes. Little y Rubin distinguen tres mecanismos: datos que faltan completamente al azar (MCAR), datos que faltan al azar condicionado a otras variables observadas (MAR) y datos cuya ausencia depende del propio valor que falta (MNAR) [9]. El mecanismo determina el tratamiento. En el ejemplo, la temperatura faltante puede completarse con la de una estación meteorológica cercana. El tráfico ausente porque la tienda no tiene contador depende de una variable observada, la antigüedad de la tienda, así que es un caso MAR; lo prudente es agregar una variable indicadora en lugar de inventar valores. Los ceros por quiebre de stock se marcan y se excluyen del entrenamiento o se reemplazan por una estimación de la demanda perdida.

Para los valores atípicos, una regla sencilla y robusta es la de Tukey [6], que marca como atípico todo valor que cumpla

$$x < Q_1 - 1{,}5 \cdot IQR \;\vee\; x > Q_3 + 1{,}5 \cdot IQR, \quad IQR = Q_3 - Q_1 \tag{1}$$

donde Q_1 y Q_3 son el primer y el tercer cuartil. En la Figura 2(a) el límite superior queda cerca de 2.084 unidades. Marcar un valor no equivale a borrarlo. Las semanas por encima de ese límite coinciden con festivos, así que lo correcto es conservarlas y añadir una variable de temporada. Si se eliminan, el modelo no sabrá qué ocurre en diciembre, que es cuando más importa acertar.

Construir y dar formato incluye llevar las variables a escalas comparables. En la cadena, el precio se mide en miles de pesos, la temperatura en grados y el tráfico en cientos de personas. Han, Kamber y Pei describen dos transformaciones de uso común [10]. La normalización min-max lleva cada variable al intervalo [0, 1]:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{2}$$

y la estandarización (puntuación z) expresa cada valor en desviaciones estándar respecto a la media:

$$z = \frac{x - \mu}{\sigma} \tag{3}$$

donde μ es la media y σ la desviación estándar de la variable. Si una tienda vende en promedio 1.200 unidades semanales con σ = 300, una semana de 1.950 unidades tiene z = (1.950 − 1.200)/300 = 2,5, es decir, está dos desviaciones y media por encima de lo habitual. La normalización min-max es sensible a los extremos, porque un solo valor atípico comprime los demás cerca de cero; por eso conviene aplicarla después de tratar los atípicos.

En una regresión lineal estimada por mínimos cuadrados ordinarios, escalar no cambia las predicciones, solo las unidades de los coeficientes. La situación cambia si el modelo usa regularización, como en ridge o lasso, porque la penalización actúa sobre el tamaño de los coeficientes y castigaría de forma desigual a variables medidas en unidades distintas. James et al. recomiendan por eso estandarizar los predictores antes de ajustar una regresión ridge [11]. Con variables estandarizadas, además, los coeficientes se pueden comparar entre sí, lo que ayuda a responder la tercera pregunta de la Tabla 2.

Hay un detalle técnico del que depende que la evaluación posterior sea honesta. La media, la desviación estándar, el mínimo y el máximo de las ecuaciones (2) y (3) deben calcularse solo con los datos de entrenamiento y luego aplicarse a los de validación. Si se calculan con el conjunto completo, el modelo recibe información del periodo con el que después será evaluado. Kaufman et al. llaman a este problema fuga de información (*leakage*) y muestran que produce resultados optimistas que no se repiten cuando el modelo se usa en la práctica [12]. En series de tiempo como las ventas semanales, esto obliga también a separar los datos por fecha y no al azar.

Por último, integrar ventas, precios, promociones y clima exige acordar una unidad de observación. Wickham propone el formato ordenado (*tidy data*): cada variable en una columna, cada observación en una fila y cada tipo de unidad observacional en su propia tabla [13]. En el ejemplo la observación es la combinación tienda-semana, y todo lo que esté a otro nivel se agrega o se desagrega antes de unir las tablas. El resultado de la fase es un conjunto de datos listo para modelar, junto con un registro de cada transformación aplicada, que permitirá repetirlas cuando lleguen datos nuevos. Con esa base, la fase de modelado puede concentrarse en elegir el algoritmo según el problema, tema de la siguiente sección.

Referencias

[1] P. Chapman et al., *CRISP-DM 1.0: Step-by-Step Data Mining Guide*. Chicago, IL, USA: SPSS Inc., 2000.

[2] F. Provost y T. Fawcett, *Data Science for Business: What You Need to Know About Data Mining and Data-Analytic Thinking*. Sebastopol, CA, USA: O'Reilly Media, 2013.

[3] F. Martínez-Plumed et al., "CRISP-DM twenty years later: From data mining processes to data science trajectories," *IEEE Trans. Knowl. Data Eng.*, vol. 33, no. 8, pp. 3048–3061, ago. 2021, doi: 10.1109/TKDE.2019.2962680.

[4] R. Y. Wang y D. M. Strong, "Beyond accuracy: What data quality means to data consumers," *J. Manage. Inf. Syst.*, vol. 12, no. 4, pp. 5–33, 1996, doi: 10.1080/07421222.1996.11518099.

[5] F. J. Anscombe, "Graphs in statistical analysis," *Amer. Statist.*, vol. 27, no. 1, pp. 17–21, 1973, doi: 10.1080/00031305.1973.10478966.

[6] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[7] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman y A. Galstyan, "A survey on bias and fairness in machine learning," *ACM Comput. Surv.*, vol. 54, no. 6, art. 115, pp. 1–35, 2021, doi: 10.1145/3457607.

[8] Anaconda Inc., "2020 State of Data Science: Moving from hype toward maturity," Austin, TX, USA, 2020. [En línea]. Disponible: https://www.anaconda.com/resources/whitepaper/state-of-data-science-2020

[9] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 3.ª ed. Hoboken, NJ, USA: Wiley, 2019.

[10] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 3.ª ed. Waltham, MA, USA: Morgan Kaufmann, 2012.

[11] G. James, D. Witten, T. Hastie y R. Tibshirani, *An Introduction to Statistical Learning: With Applications in R*, 2.ª ed. Nueva York, NY, USA: Springer, 2021.

[12] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, art. 15, pp. 1–21, 2012, doi: 10.1145/2382577.2382579.

[13] H. Wickham, "Tidy data," *J. Stat. Softw.*, vol. 59, no. 10, pp. 1–23, 2014, doi: 10.18637/jss.v059.i10.